

Grundlagen Datenbanken: Übung 11

Tanmay Deshpande

Gruppe 20 & 21

ge94vem@mytum.de





QR-Code für die Folien





Wiederholung

Woche 11






Anfrageoptimierung

- Ziel: Anfrage soll möglichst effizient ausgewertet werden
- 1. Logische Optimierung: Relationale Algebra Ausdrücke werden mithilfe von äquivalenzerhaltender Umformungen optimiert
 - 2. **Physische Optimierung:** Algorithmische Optimierung von der Datenverarbeitung (Bsp: Join-Algorithmen)



Logische Optimierung

• Zuerst, braucht man die kanonische Übersetzung der SQL-Anfrage



Danach, äquivalenzerhaltende Transformationsregeln anwenden


Äquivalenzerhaltende Transformationsregeln



1. Aufspalten von Selektionsprädikaten



2. Kommutative Selektionen



3. π -Kaskaden (falls $A \subseteq B$)




- 4. σ und π Umtausch (wenn sich die Prädikate auf die gleichen Attribute beziehen)
- 5. Kommutative \times , \cup , \cap , \bowtie
- 6. σ und \bowtie Umtausch (wenn sich σ nur auf Attribute in R bezieht)
- 7. π und \bowtie Umtausch (wenn sich die Prädikate auf die gleichen Attribute beziehen)

Äquivalenzerhaltende Transformationsregeln



8. Assoziative × , ∪, ∩ , ⋈



9. σ distributiv mit \cup , \cap , -



- 10. π distributiv bezüglich ∪
- 11. Join\Selektionsprädikate mit De-Morgan umformen

Äquivalenzerhaltende Transformationsregeln



12. Selektionen und Kreuzprodukt zu Joins zusammenführen (wenn sie sich auf die gleichen Attribute beziehen)





Logische Optimierung

- Mithilfe der äquivalenzerhaltenden Transformationsregeln können wir die kanonische Übersetzung einer SQL-Anfrage optimieren.
- Ziele:
 - Bearbeitungsreihenfolge der Operationen so zu ändern, dass die kleinstmögliche Zwischenergebnisse entstehen.
 - Zusammenfassen von Operationen
- Vorschrift:
 - 1. Selektionen aufbrechen
 - 2. Selektionen nach unten verschieben
 - 3. Selektionen und Kreuzprodukte zu Joins zusammenfassen
 - 4. Joinreihenfolge bestimmen
 - 5. Projektionen Einfügen
 - 6. Projektionen nach unten verschieben



Physische Optimierung

- Wie werden Operationen der relationalen Algebra durchgeführt?
- Wie werden Indizes verwendet (falls vorhanden)?
- Sollen Zwischenergebnisse vollständig berechnet und gespeichert werden?
- Welcher Algorithmus sollte je nach Situation angewendet werden, um die nötigen Daten zu bestimmen?
- Bsp: Join-Algorithmen


Iteratoren:

- * Erlauben uns, verschiedene Implementierungen gegeneinander auszutauschen
- * Zwischenergebnisse können verwendet werden ohne sie komplett zu speichern



Iteratoren

- open: Initialisierung der Eingabe
- next: Berechnet das n\u00e4chste Tupel des Ergebnisses und gibt es zur\u00fcck
- close: Schleißt und gibt die Ressource frei
- cost/size: Geschätzte
 Berechnungskosten bzw.
 Ergebnisgröße





Nested Loop Join

- Brute-force Algorithmus
- foreach $r \in R$ foreach $s \in S$ if s.B = r.Athen $Res := Res(r \cdot s)$
- $O(n^2)$ Komplexität

iterator $NestedLoop_p$

open

• Öffne die linke Eingabe

next

- Rechte Eingabe geschlossen?
 - Öffne sie
- Fordere rechts solange Tupel an, bis Bedingung p erfüllt ist
- Sollte zwischendurch rechte Eingabe erschöpft sein
 - Schließe rechte Eingabe
 - Fordere nächstes Tupel der linken Eingabe an
 - Starte **next** neu
- Gib den Verbund von aktuellem linken und aktuellem rechte Tupel zurück


close

• Schließe beide Eingabequellen



Index Join

- Wie Nested-Loop, aber anstatt für jeden Join-Partner in der linken Relation die ganze rechte Relation durchzugehen, suchen wir nach passenden Werten der rechten Relation mithilfe einer Indexstruktur (Bsp: B-Baum)
- Da diese sortiert sind, erleichtert es unsere Suche im Vergleich zu Brute-Force



- Dafür muss so eine Struktur existieren und es kann aufwendig sein sie zu erstellen
- $O(|R| \cdot \log|S|)$ Komplexität



Index Join

iterator IndexJoin_p

open:

- linke Eingabe öffnen
- erstes Tupel von der linken Eingabe anfordern

next:

- schlage Join-Attributwert im Index nach
- Match gefunden? Verbinde die Tupel und gibt das Ergebnis zurück
- Sonst, der nächste Tupel von der linken Eingabe anfordern und next wiederholen
- Abbruch: linke Eingabe erschöpft

close: beide Eingaben schleißen



- Voraussetzung: Joinattribute sind sortiert
- Idee: Weil unsere Eingaben sortiert sind, wenn man auf einen großeren Wert als das aktuelle Joinattribut landet, weiß man, dass man alle mögliche Join-Partner erschöpft hat. Beim nächsten Scan muss man die Einträge davor nicht nochmal betrachten

Setup:

- Die beiden Eingaben haben jeweils einen Pointer auf ihre Einträge
- akt. Die aktive Eingabe mit dem Pointer auf den kleineren Wert
- -"andere" Eingabe: Die inaktive Eingabe
- Markierung: Wir merken uns die Stelle in der "anderen" Eingabe, wo wir unser Scan für den nächsten Eintrag beginnen müssen



- Voraussetzung: Die Join-Attribute sind sortiert
- iterator MergeJoin_p

open:


- Öffne beide Eingaben
- Setze akt auf linke Eingabe
- Markiere rechte Eingabe

next:

- Solange Bedingung nicht erfüllt
 - Setze akt auf Eingabe mit dem kleinsten anliegenden Wert im Joinattribut
 - Bewege akt vor
 - Markiere andere Eingabe
- Verbinde linkes und rechtes Tupel
- Bewege andere Eingabe vor
- Ist Bedingung nicht mehr erfüllt oder eine andere Eingabe erschöpft?
 - Bewege akt vor
 - Hat sich der Wert des Joinattributs in akt verändert?
 - Ja: markiere die andere Eingabe
 - Nein: setze andere Eingabe auf Markierung zurück




akt



- Bedingung nicht erfüllt
 - akt auf kleineren Wert setzen
 - Bewege akt vor
 - Markiere andere Eingabe




akt




- Bedingung nicht erfüllt
 - akt auf kleineren Wert setzen
 - Bewege akt vor
 - Markiere andere Eingabe






- Bedingung nicht erfüllt
 - akt auf kleineren Wert setzen
 - Bewege akt vor
 - Markiere andere Eingabe






- Bedingung erfüllt
 - Verbinde die Tupel
 - Bewege andere Eingabe vor






- Bedingung erfüllt
 - Verbinde die Tupel
 - Bewege andere Eingabe vor






- Bedingung nicht mehr erfüllt
 - Bewege akt vor
 - Join-Wert von akt hat sich verändert
 - Markiere andere Eingabe






- Bedingung erfüllt
 - Verbinde die Tupel
 - Bewege andere Eingabe vor






- Bedingung erfüllt
 - Verbinde die Tupel
 - Bewege andere Eingabe vor






- Bedingung nicht mehr erfüllt
 - Bewege akt vor
 - Join-Wert von akt hat sich nicht verändert
 - Springe zurück zu Markierung in anderer Eingabe






- Bedingung erfüllt
 - Verbinde die Tupel
 - Bewege andere Eingabe vor






- Bedingung erfüllt
 - Verbinde die Tupel
 - Bewege andere Eingabe vor





- Bedingung nicht mehr erfüllt
 - Bewege akt vor
 - Join-Wert von akt hat sich verändert
 - Markiere die andere Eingabe







Hash Join

- Die gleiche Hashfunktion wird auf die Join-Attributwerte der beiden Relationen angewendet
- Die Hashfunktion verteilt diese Werte in verschiedenen Buckets. Äquivalente Werte der beiden Relationen landen im selben Bucket. Somit können Join-Partner gefunden werden
- Eignet sich für Equi-Joins
- O(|R| + |S|) Komplexität




Aufgaben

Woche 11







Aufgabe 01





Lösungsvorschlag 01 a













Lösungsvorschlag 01 b





Lösungsvorschlag 01 b (contd...)







Aufgabe 02

- a) Was ist ein Equi-Join?
 - b) Bei welchen Join-Prädikaten (<,=,>) kann man sinnvoll einen Hashjoin einsetzen?
 - c) Gegeben die Relation Profs = $\{\underline{PersNr}, Name\}$ und Raeume = $\{\underline{PersNr}, RaumNr\}$.
 - 1) Skizzieren Sie eine geschickte Möglichkeit, den Equi-Join Profs ⋈ Raeume durchzuführen.
 - 2) In welchem Fall wäre selbst ein Ausdruck wie

Profs ⋈_{Profs.Persnr} < Raeume.PersNr Raeume

effizient auswertbar?

d) Der Student Maier hat einen Algorithmus gefunden, der den Ausdruck $A \times B$ in einer Laufzeit von O(|A|) materialisiert. Was sagen Sie Herrn Maier?



Lösungsvorschlag 02a)-c)

- a) Ein Equi-Join hat eine Äquivalenz als Joinbedingung, etwa die Gleichheit zweier Attribute.
- b) Ein Hash Join bietet sich nur für Equi-Joins an, da lediglich ein Join-Partner mit gleichem Attributwert effizient auffindbar ist. Das Finden eines Partners, dessen Attributwert beispielsweise kleiner sein soll kann mittels Hashing i.A. nicht effizient bearbeitet werden.
- c)
 - 1) Offenbar ist das Joinattribut gerade der Primärschlüssel, womit von der Existenz eines Indexes ausgegangen werden kann. Somit bietet sich ein Index-basierter Join an, etwa dadurch, dass die eine Relation Element für Element abgearbeitet wird, während Joinpartner aus der anderen Relation mittels des Indexes gefunden werden.
 - 2) Falls der Index sortiert ist, dies wäre etwa bei einem B-Baum der Fall. Dadurch liegen Joinpartner zumindest nacheinander im Index, anders als bei einer Implementierung des Indexes mittels Hash.



Lösungsvorschlag 02d

- Dies ist mit Sicherheit nicht der Fall, da ein Algorithmus keine bessere Komplexitätsklasse haben kann als sein Ergebnis wächst.
- Mit anderen Worten, A x B hat eine Ergebnisgröße von |A| · |B| und dieses Ergebnis kann sicher nicht schneller als in O(|A| · |B|) materialisiert werden.




Aufgabe 03

- Gegeben sei die folgende SQL-Anfrage: select distinct a.PersNr, a.Name from Assistenten a, Studenten s, pruefen p where s.MatrNr = p.MatrNr and a.Boss = p.PersNr and s.Name = 'Jonas';
- Skizziere die kanonische Übersetzung in relationaler Algebra als Operatorbaum
- Führe die logische Optimierung aus nach dem Vorschrift aus der Vorlesung (gehe von realistischen Kardinalitäten aus)
- Optimierungstechniken:
 - Aufbrechen von Selektionen
 - Verschieben von Selektionen nach "unten" im Plan
 - Zusammenfassen von Selektionen und Kreuzprodukten zu Joins
 - Bestimmung der Joinreihenfolge



Lösungsvorschlag 03


Kanonische Übersetzung:





Lösungsvorschlag 03 (contd...)

Logische Optimierung:



Aufgabe 04



 Gegeben seien die folgenden Relationenausprägungen:

R					
	A				
	0				
	5				
	7				
	8				
	8				
	10				
:	:				

S						
В						
5						
6						
7	:					
8	•••					
8	:					
11						
:	:					

Wende Nested Loop und Merge Join auf die Relationen an und vervollständige die Tabellen mit der Bearbeitungsreihenfolge der Einträge

		S.B					
		5	6	7	8	8	11
R.A	0	1	2	3			
	5						
	7						
	8						
	8						
	10						

Nested-Loop-Join

		S.B					
		5	6	7	8	8	11
	0	1					
R.A	5	21					
	7						
	8						
	8						
	10						

Sort/Merge-Join

Lösungsvorschlag 04: Nested Loop



		S.B						
		5	6	7	8	8	11	
	0	1	2	3	4	5	6	
R.A	5	71	8	9	10	11	12	
	7	13	14	15	16	17	18	
	8	19	20	21	221	231	24	
	8	25	26	27	28•	29•	30	
	10	31	32	33	34	35	36	

Nested-Loop-Join

Lösungsvorschlag 04: Merge Join



Ausfürhliche Lösung:


http://www-db.in.tum.de/teaching/ws1415/grundlagen/Loesung11_sort_merge_join.pdf

		S.B					
		5	6	7	8	8	11
	0	1					
R.A	5	21	3				
	7		4	5 🗸			
	8			6	71	10	
	8				8 🗸	111	
	10				9	12	13

Sort/Merge-Join



Aufgabe 05



Sind die beiden Algebraausdrücke äquivalent? Begründen Sie!



Lösungsvorschlag 05

- Die Ausdrücke sind nicht äquivalent
- Die Selektion in 2. filtriert Vorlesungen heraus, die zu Ergebnis von 1. gehören
- Bsp: Ethik gehört zu Ergebnis von 1. aber nicht von 2.